

Entendendo Blocklists de Nível Comunitário em Redes Sociais Descentralizadas

Zhang, Hwang, Liu, Horta Ribeiro & Monroy-Hernández — Princeton University (2025)

Moderação de conteúdo no Mastodon / Fediverse • [arXiv:2506.05522](https://arxiv.org/abs/2506.05522)

Apresentação de artigo

Contexto e Motivação

Por que estudar blocklists?

- Moderação = decidir o que aceitar ou rejeitar para manter o diálogo civil (o "paradoxo da tolerância" de Popper).
- Pesquisa anterior focou em plataformas centralizadas (X, Reddit) e em blocklists individuais.
- No Mastodon / Fediverse não existe "plataforma": milhares de instâncias independentes conectadas via protocolo ActivityPub.
- Cada instância define suas próprias regras — não há autoridade central de moderação.
- A principal ferramenta entre instâncias é a blocklist de nível comunitário: bloquear instâncias inteiras.

O impacto do bloqueio

Bloquear instâncias grandes (ex.: mastodon.social) pode cortar a comunidade de grande parte do Fediverse.

Decisões de nível comunitário são muito mais impactantes que bloqueios individuais.

Falsos positivos têm consequências sérias.

Perguntas de Pesquisa

Abordagem de métodos mistos

RQ1

Qual é o panorama atual das blocklists de nível comunitário?

RQ2

Como moderadores interpretam e aplicam as blocklists na prática?

RQ3

Que melhorias de design tornariam essas ferramentas mais úteis e eficazes?

1 · Análise de Conteúdo

- ~8.700 instâncias Mastodon; analisadas 1.807 (≥ 10 usuários ativos).
- 5 blocklists compartilhadas (Garden Fence, CARIAD, IFTAS-DNI, Seirdy Tier-0, FediNuke).
- 4 ferramentas (FediCheck, FediBlockHole, Fediseer, The Bad Space).
- Categorias: propósito, critérios, transparência, distribuição, limitações.

2 · Entrevistas Semiestruturadas

- 12 moderadores do Mastodon, 7 países, 26–55 anos.
- ~1 hora cada, via Zoom; análise temática.
- 1ª metade: práticas atuais de uso das blocklists (RQ2).
- 2ª metade: protótipo (React/Vite) como "design probe" — filtros por categoria, níveis de severidade e comentários (RQ3).

RQ1 — Panorama das Blocklists

Heterogêneas e pouco transparentes

- Só 20,1% das 1.807 instâncias compartilham publicamente sua blocklist.
- Entre essas, menos da metade (46,4%) dá o motivo do bloqueio → lacuna de transparência.
- Instâncias maiores compartilham mais (1000+ usuários: 45,3% vs. 10–24: 13,9%).
- Blocklists baseiam-se em curadoria manual e fontes externas, muitas vezes não divulgadas.
- Vieses recorrentes: foco no inglês, perspectiva do Norte Global, atualização lenta.

Top motivos de bloqueio

Spam **69,8%**

Assédio / Troll **50,3%**

Bots **47,3%**

Discurso de ódio **37,9%**

CSAM / abuso infantil **33,7%**

Desinformação **29,6%**

Transfobia **21,9%**

Racismo **17,8%**

RQ1 — Blocklists e Ferramentas

Diferentes filosofias de moderação

Garden Fence / CARIAD	Ampla consenso; domínios amplamente bloqueados (protege por abrangência).
IFTAS-DNI / FediNuke	Foco em severidade: instâncias notoriamente prejudiciais.
Seirdy Tier-0	Consenso (≥ 15 de 27 listas); "receipts" documentando decisões.
FediCheck / FediBlockHole	"Moderação como serviço": sincroniza listas confiáveis, usuário mantém controle.
Fediseer / The Bad Space	Classificação e transparência; sinaliza instâncias via múltiplas comunidades.

RQ2 — Três Abordagens de Decisão

Prioridades concorrentes na moderação

Abertura

Reativa, baseada em denúncias

✓ Valoriza conexão e livre expressão.

⚠ Risco: exposição a atores nocivos.

Segurança

Proativa, baseada em busca

✓ Bloqueio antecipado de más instâncias.

⚠ Risco: penalizar atores de boa-fé.

Contexto

Revisão manual e cuidadosa

✓ Decisões justas e ponderadas.

⚠ Risco: muito trabalhosa.

Não são mutuamente exclusivas: moderadores alternam entre as abordagens conforme valores, metas e recursos da comunidade.

RQ3 — Necessidades de Design

O que tornaria as blocklists melhores

Colaboração comunitária

Votação interna, listas de "suspeitos", bibliotecas públicas de "receipts", scorecards e um "marketplace de blocklists".

Eficiência e gestão

Filtros por categoria (spam, assédio...), automação para detectar e aplicar bloqueios, integração ao Mastodon.

Monitoramento e visibilidade

Métricas por instância (atividade, população, denúncias), quem mais bloqueou, comentários e "receipts" com data/fonte.

Discussão

Implicações para moderação descentralizada

- Equilibrar prioridades concorrentes: abordagem híbrida integra abertura, segurança e contexto em vez de opô-las.
- Responsabilidade ampliada: bloqueios comunitários podem isolar comunidades inteiras — poder e risco maiores para moderadores.
 - O verdadeiro obstáculo não é falta de consciência dos moderadores, e sim a inadequação das ferramentas atuais.
- Moderação colaborativa entre instâncias: documentação estruturada, tags universais, suporte multilíngue e "covenants digitais".
- Transparência confiável: métricas de domínio e metadados sobre origem e critérios das listas aumentam confiança e legitimidade.

Limitações e Conclusão

Limitações

- Amostra pequena (12 moderadores) → generalização limitada.
- Foco em recursos populares e em inglês → possível viés de seleção.
- Práticas de moderação são dinâmicas e mudam ao longo do tempo.

Conclusão

- Blocklists comunitárias são essenciais e refletem filosofias diversas de moderação.
- Moderadores transitam entre abertura, segurança e contexto.
- Persistem desafios de esforço, transparência e colaboração.
- Futuro: ferramentas flexíveis, transparentes e colaborativas para comunidades descentralizadas resilientes.

Obrigado!

Perguntas e discussão

Zhang, Hwang, Liu, Horta Ribeiro & Monroy-Hernández (2025) — Princeton University · arXiv:2506.05522